



PROPOSTA E AVALIAÇÃO DE UM ALGORITMO PARA PROMOVER ATAQUES DE QUEBRA DE PRIVACIDADE EM REDES ANONIMIZADAS

Pamela Tabak

Projeto de Graduação apresentado ao Curso de Computação e Informação da Escola Politécnica da Universidade Federal do Rio de Janeiro como parte dos requisitos necessários para a obtenção do grau de Engenheiro de Computação e Informação.

Orientador: Daniel Ratton Figueiredo

Rio de Janeiro
Julho de 2017

PROPOSTA E AVALIAÇÃO DE UM ALGORITMO PARA PROMOVER
ATAQUES DE QUEBRA DE PRIVACIDADE EM REDES ANONIMIZADAS

Pamela Tabak

PROJETO SUBMETIDO AO CORPO DOCENTE DO CURSO DE
COMPUTAÇÃO E INFORMAÇÃO DA ESCOLA POLITÉCNICA DA
UNIVERSIDADE FEDERAL DO RIO DE JANEIRO COMO PARTE
DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE
ENGENHEIRO DE COMPUTAÇÃO E INFORMAÇÃO.

Examinadores:

Prof. Daniel Ratton Figueiredo, Dr.

Prof. Fernando Gil Vianna Resende Junior, Dr.

Prof. Flávio Luis de Mello, Dr.

RIO DE JANEIRO, RJ – BRASIL
JULHO DE 2017

Tabak, Pamela

Proposta e Avaliação de um Algoritmo para Promover Ataques de Quebra de Privacidade em Redes Anonimizadas/Pamela Tabak. – Rio de Janeiro: UFRJ/POLI – COPPE, 2017.

X, 51 p.: il.; 29, 7cm.

Orientador: Daniel Ratton Figueiredo

Projeto (graduação) – UFRJ/ Escola Politécnica/ Curso de Computação e Informação, 2017.

Referências Bibliográficas: p. 50 – 51.

1. Grafos. 2. Redes Sociais. 3. Anonimização. 4. Privacidade em Mineração de Dados. 5. Redes Complexas. I. Figueiredo, Daniel Ratton. II. Universidade Federal do Rio de Janeiro, Escola Politécnica/ Curso de Computação e Informação. III. Título.

Agradecimentos

Agradeço ao meu pai, que sempre me incentivou e me ensinou que dedicação e esforço trazem bons resultados. À minha mãe, que desde pequena me mostrou o que era ter força e determinação e sempre acreditou que eu seria capaz de ser boa naquilo que eu gostasse. Aos dois, agradeço pelo amor incondicional e todo apoio fornecido, além de me mostrarem o caminho para o mundo da engenharia.

Agradeço a todos os meus amigos, pessoas com quem eu puder contar e confiar em todos os momentos e me fizeram ter lembranças e histórias maravilhosas para contar. Em especial, ao meu melhor amigo e namorado, Eric Reis, que me apoiou ao longo deste projeto, assim como durante toda a faculdade.

À Universidade Federal do Rio De Janeiro, sou grata por ter passado os últimos anos aqui. Muito antes de saber o curso que iria fazer, já tinha escolhido a universidade que desejava estudar. Aos professores do curso, agradeço por todas as aulas lecionadas, dentro e fora de sala, que me deram as ferramentas necessárias para me tornar engenheira.

Por fim, agradeço ao professor Daniel Figueiredo, por todos os ensinamentos passados ao longo da faculdade e pela disposição e motivação em orientar este projeto.

Resumo do Projeto de Graduação apresentado à Escola Politécnica/COPPE/UFRJ como parte dos requisitos necessários para a obtenção do grau de Engenheiro de Computação e Informação.

**PROPOSTA E AVALIAÇÃO DE UM ALGORITMO PARA
PROMOVER ATAQUES DE QUEBRA DE PRIVACIDADE EM
REDES ANONIMIZADAS**

Pamela Tabak

Julho/2017

Orientador: Daniel Ratton Figueiredo

Curso: Engenharia de Computação e Informação

Os traços digitais da interação social humana são facilmente encontrados ao redor da *Web*. Sites com relacionamentos sociais entre seus usuários têm se tornado cada vez mais comuns e facilmente aceitos e usados pela população. Assim, essas fontes têm crescido muito e consequentemente se tornado base de dados para estudos de larga escala. Entretanto, muitas destas redes não são públicas, isto é, as relações entre usuários são privadas, como o grafo que representa a troca de e-mails. Nesse contexto, ataques de quebra de privacidade surgem para revelar relações entre usuários da mesma rede: estariam dois políticos influentes trocando mensagens, por exemplo? Este trabalho propõe e avalia um método para realizar um ataque contra a privacidade dos usuários de grafos anonimizados, isto é, que não possuem a identificação de cada usuário.

Palavras-Chave: Grafos, Redes Sociais, Anonimização, Privacidade em Mineração de Dados, Redes Complexas.

Abstract of the Undergraduate Project presented to Poli/COPPE/UFRJ as a partial fulfillment of the requirements for the degree of Computer and Information Engineer.

PROPOSAL AND EVALUATION OF AN ALGORITHM TO PROMOTE PRIVACY BREACH IN ANONYMISED NETWORKS

Pamela Tabak

July/2017

Advisor: Daniel Ratton Figueiredo

Course: Computer and Information Engineering

The digital traces of human social interactions are easily found all over the Web. Websites with social relationship among their users are increasingly common and easily accepted and used by the population. Those sources have grown greatly and consequently became interesting data for large-scale studies. However, many of those networks are not public, that is, the relationship between users are private, such as the graph representing e-mails exchange. In this context, privacy breach attacks arise, in order to reveal relationship between users inside the same network: are two influential politicians exchanging messages, for example? This work proposes and evaluates a method to promote an attack against the privacy of the users inside an anonymized network, that is, a graph which doesn't show the identification of each user.

Keywords: Graphs, Social Networks, Anonimization, Privacy in Data Mining, Complex Networks.

Sumário

Lista de Figuras	ix
Lista de Tabelas	x
1 Introdução	1
1.1 Tipos de Ataque	2
1.1.1 Ativo	2
1.1.2 Passivo	2
1.1.3 Híbrido	3
1.2 Motivação	3
1.3 Objetivo	4
1.4 A técnica	5
1.5 Estruturação do documento	6
2 Trabalhos Relacionados	7
2.1 <i>Anonymized social networks, hidden patterns, and structural steganography</i>	7
2.1.1 Ataque passivo	7
2.1.2 Ataques ativos	8
2.2 <i>Resisting structural re-identification in anonymized social networks</i> . .	9
3 Algoritmo proposto	12
3.1 Explicação detalhada	12
3.1.1 Criação dos atacantes	12
3.1.2 Anonimização do grafo	21
3.1.3 Recuperação do subgrafo	24
3.2 Implementação	28
4 Avaliação	30
4.1 Metodologia da avaliação	30
4.2 Resultados	31
4.2.1 Grafos aleatórios	31

4.2.2	Redes reais	35
5	Detecção do ataque	42
5.1	Detecção de comunidade	42
5.1.1	Método de Louvain	43
5.1.2	Resultados	44
6	Conclusão e trabalhos futuros	47
6.1	Conclusão	47
6.2	Trabalhos futuros	48
6.2.1	Maior abrangência	48
6.2.2	Comparações	48
6.2.3	Remoção de arestas	48
6.2.4	Detecção do ataque	49
	Referências Bibliográficas	50

Lista de Figuras

1.1	<i>Exemplo de um grafo anonimizado após sofrer o ataque</i>	6
3.1	<i>Exemplo do subgrafo de atacantes após adição inicial de arestas . . .</i>	15
3.2	<i>Exemplo do subgrafo de atacantes após adição de todas as arestas entre os atacantes</i>	15
3.3	<i>Automorfismo em grafo</i>	18
3.4	<i>Isomorfismo em grafos</i>	19
3.5	<i>Grafo para exemplificar componente de anonimização</i>	22
3.6	<i>Grafo anonimizado pelo processo de anonimização a partir do índice de cada nó</i>	23
3.7	<i>Grafo anonimizado pelo processo de anonimização a partir da per- mutação entre os identificadores</i>	24
3.8	<i>Árvore exemplificando a recuperação dos atacantes no grafo anonimi- zado</i>	26
3.9	<i>Árvore representando o sucesso na recuperação dos atacantes no grafo anonimizado</i>	27

Lista de Tabelas

3.1	Tabela representando vetor de marcação de atacantes a cada instante, com 4 atacantes.	16
3.2	Tabela representando resultados do processo de anonimização a partir do índice de cada nó.	22
3.3	Tabela representando resultados do processo de anonimização a partir da permutação entre os identificadores.	23
4.1	Tabela representando desempenho do algoritmo no modelo Erdős-Rényi.	32
4.2	Tabela representando desempenho do algoritmo no modelo Barabási-Albert.	34
4.3	Tabela representando desempenho do algoritmo em uma rede do Facebook.	36
4.4	Tabela representando desempenho do algoritmo na rede de votação da Wikipédia.	38
4.5	Tabela representando desempenho do algoritmo na rede de compartilhamento de arquivo Gnutella P2P.	40
5.1	Tabela representando informações sobre as comunidades na rede do Facebook.	45
5.2	Tabela representando informações sobre as comunidades na rede Gnutella P2P.	45
5.3	Tabela representando informações sobre as comunidades na rede do modelo Erdős-Rényi.	46

Capítulo 1

Introdução

Os traços digitais da interação social humana são facilmente encontrados ao redor da *Web*. Sites com relacionamentos sociais entre seus usuários têm se tornado cada vez mais comuns e facilmente aceitos e usados pela população, para diversos fins. Consequentemente, essas fontes se tornaram, nos últimos anos, dados importantes para estudos de larga escala de redes sociais.

Em muitas dessas fontes de dados de interação social, o relacionamento entre os usuários é público, isto é, a informação que dois usuários da rede estão conectados pode ser obtida por qualquer outro usuário. Esse seria o caso do Facebook, por exemplo, em que as relações entre usuários são públicas. Entretanto, existem muitas redes sociais em que essas relações não são disponibilizadas, de modo que cada usuário conheça apenas as relações que ele possui, desconhecendo a existência de relações entre dois outros usuários da rede. Um exemplo desse tipo de rede seria a de troca de e-mail: cada usuário sabe para quem ele já enviou e de quem ele já recebeu e-mails, porém ele não é capaz de saber se um usuário qualquer já enviou ou recebeu algum e-mail de outro usuário. Nessas redes, cada usuário é capaz de estimar corretamente o valor do seu próprio grau, porém a única informação que eles podem assumir, relativa ao grau, de seus vizinhos, é que vale pelo menos um, uma vez que pelo menos uma relação entre o vizinho e outro usuário, no caso ele mesmo, é conhecida.

Apesar de muitas redes serem privadas, isto é, não disponibilizarem a relação entre seus usuários publicamente, existem maneiras de se obter estas informações. Uma delas, o foco deste trabalho, são ataques que visam revelar relações entre usuários de um grafo anonimizado, isto é, não contém a identificação de cada usuário.

No mundo tecnológico é comum que as detentoras dessas redes divulguem um grafo anonimizado que as representam, de modo a permitir que estudos empíricos sejam feitos, que não necessitem da identidade de cada usuário, por exemplo. Um caso assim foi o da Netflix, descrito em [1], que criou uma competição online para a criação de um sistema de recomendação que a empresa pudesse usar e fosse melhor

do que o que ela já usava. Dessa forma, milhares de pessoas ao redor do mundo puderam dar ideias para a criação desse sistema de recomendação, a partir de um grafo anonimizado, em que a identidade dos usuários e filmes foi escondida.

Muitas vezes, antes de uma empresa divulgar a rede anonimizada, ela anuncia que fará essa liberação de dados, por diversos motivos. Sendo assim, é durante esse período que um ataque pode ocorrer: sabendo que um grafo anonimizado que representa uma rede será liberado, é possível inserir informações nesta rede antes dela ser liberada, que alterem parte de sua estrutura. Dessa forma, ao ter um grafo anonimizado, é possível procurar pelas informações inseridas e tentar identificar usuários.

1.1 Tipos de Ataque

Nessa conjectura, existem algumas abordagens proeminentes [2]: ativo, passivo e híbrido. Em todos os ataques citados, o promotor do ataque precisa definir um conjunto de nós da rede a serem atacados, isto é, a terem suas privacidades violadas.

1.1.1 Ativo

Ataques ativos são algoritmos em que novos usuários são adicionados à rede pelo promotor do ataque, chamados de nós atacantes, que também irá adicionar relações tanto entre esses nós quanto entre os nós atacantes e os nós atacados. Nesse contexto, nós atacados são os usuários da rede que o atacante deseja violar a privacidade e relações entre nós são as arestas de um grafo.

Como o promovedor do ataque insere nós e arestas no grafo propositalmente, ele passa a ter alguma informação sobre a estrutura da rede, que até então era completamente desconhecida para ele. Informações estruturais sobre os vértices que ele criou que não dependam de outras métricas, como o grau, passam a ser dados conhecidos, uma vez que o atacante criou estes nós e as relações entre eles. A ideia é, portanto, a partir dessas informações, encontrar os nós adicionados, nós atacantes, no grafo anonimizado, de modo a identificar os nós atacados a partir da maneira como as relações foram criadas entre esses e os atacantes.

Neste ataque, qualquer usuário da rede pode ser escolhido para ser atacado.

1.1.2 Passivo

Neste ataque, os promotores do ataque são alguns dos próprios usuários do sistema a ser atacado. Eles não criam novos usuários ou novas arestas, usando a informação que eles possuem da rede, deles mesmos, para encontrá-los na rede anonimizada e,

a partir disto, tentar descobrir arestas entre usuários a quem eles estão relacionados. Nestes casos, cada usuário da rede conhece seus vizinhos, podendo estimar seu próprio grau, por exemplo.

No ataque passivo, por sua vez, apenas usuários relacionados ao grupo de usuários atacantes podem ser atacados, limitando a informação que será extraída da rede. Entretanto, este ataque não altera a estrutura da rede, de modo que ele seja mais dificilmente detectado como um possível ataque.

1.1.3 Híbrido

Existem prós e contras em relação aos ataques passivo e ativo. Os ataques ativos têm efeitos mais potentes, uma vez que ele não precisam depender na chance de um usuário (ou um conjunto de usuários) encontrar-se de forma única no grafo anonimizado, além do atacante poder escolher qualquer usuário da rede para violar a privacidade. Por outro lado, enquanto o ataque passivo é apenas capaz de comprometer os usuários que estão conectados ao grupo de atacantes, ele possui uma característica impressionante de que o atacante é simplesmente um usuário do sistema que vê a rede anonimizada, não alterando a estrutura da rede, de modo que não exista erro observável a ser detectado. O ataque híbrido, também conhecido por ataque semi-passivo, portanto, surgiu para tentar juntar as qualidades dos dois ataques.

Neste ataque, os promotores do ataque também são usuários do sistema. Eles não criam nenhum novo usuário, porém criam algumas novas arestas para os usuários atacados antes da rede ser divulgada, de forma a poder atacar qualquer usuário da rede e não apenas aqueles aos quais eles já estavam conectados.

1.2 Motivação

É inegável afirmar que as redes sociais se tornaram parte do cotidiano de muita gente. O Facebook, um dos maiores exemplos do início do século XXI, chegou a 1.6 bilhão de usuários em 2016, cerca de metade da população mundial com acesso à internet contabilizada neste mesmo ano.

Neste contexto, é possível perceber que com o aumento de usuários da rede, mais fácil se torna a adesão de novos usuários. Primeiro porque a rede social em questão se torna cada vez mais divulgada e atinge mais pessoas conforme o número de usuários aumenta. Segundo, nós nos sentimos mais seguros em relação à um serviço quando várias pessoas conhecidas estão o utilizando. A dúvida que resta tirar é: nossos dados estão realmente seguros nestas redes?

A privacidade em redes, e na Web em geral, continua sendo um assunto im-

portante e muito comentado. De tempos em tempos é possível ver no noticiário grandes empresas que tiveram parte de seus dados hackeados, o que acabou com a privacidade que muitas pessoas acreditavam ter seus dados protegidos.

Dessa forma, a criação de ataques contra a privacidade em redes se torna um assunto cada vez mais interessante por principalmente dois motivos: é mais fácil se proteger de ataques que são conhecidos, de modo que empresas criem os ataques para testar os níveis de proteção contra os mesmos; informações importantes podem ser extraídas dessas redes, de modo que atraia a atenção de pessoas que desejam conhecer relações, como a confirmação de troca de mensagens entre dois usuários.

1.3 Objetivo

O objetivo deste trabalho é apresentar o método desenvolvido para identificar nós pré-determinados no caso das redes em que não se tem informação sobre as relações entre os demais nós, como a rede de e-mail citada. Isto é, nas redes trabalhadas, cada usuário conhece apenas as suas relações, sendo o objetivo do trabalho encontrar relações entre os nós escolhidos para terem sua privacidade quebrada, chamados de nós atacados. Este algoritmo seguirá os princípios de um ataque ativo.

A identificação dos nós escolhidos para serem atacados será feita em grafos não-direcionados e anonimizados, a partir da estrutura da rede. O algoritmo foi elaborado com o intuito de não existir restrição quanto ao número de nós atacados, isto é, a ideia é tornar possível a identificação de qualquer quantidade de nós na rede, inclusive de todos os nós. Para isso, também é levado em consideração que o número de nós a serem adicionados na rede, por ser um ataque ativo, deverá ser um número pequeno quando comparado ao tamanho da rede. O cálculo detalhado do número de nós a serem adicionados usados neste projeto é apresentado no capítulo 3.

Além disso, a eficácia do método será analisada, para diferentes conjuntos de nós atacados, de tamanhos distintos. Serão considerados apenas dois possíveis resultados do algoritmo: sucesso, quando todos os nós atacados foram identificados, e falha, no caso contrário. Para isso, diferentes redes serão analisadas no capítulo 4, como redes aleatórias geradas a partir de modelos matemáticos e redes reais, fazendo um estudo comparativo em relação ao número de nós atacados. De modo a tornar possível a avaliação do método, isto é, averiguar quantas vezes foi sucedido ou não, este trabalho irá analisar redes não anonimizadas, simulando a anonimização após a adição dos nós atacantes e suas arestas na rede original.

A escolha pelo ataque ativo ocorreu de modo a tornar possível o ataque a qualquer usuário de qualquer rede, sem a necessidade do atacante já estar infiltrado na mesma. A maior desvantagem deste tipo de ataque, segundo [2], é a probabilidade deste tipo de ataque ser detectado, uma vez que ele tentar inserir um subgrafo na rede que se

destaque, para que o próprio atacante possa o reconhecer. Este trabalho irá abordar, no capítulo 5, brevemente sobre a detecção do ataque. Os grafos não-direcionados, por sua vez, foram optados devido a maior dificuldade em trabalhar com estes na identificação de nós, porém o algoritmo pode ser facilmente adaptado para aceitar grafos direcionados.

1.4 A técnica

A técnica desenvolvida terá dois componentes principais: a criação de nós atacantes e a identificação dos nós atacados, que será feita a partir da identificação do subgrafo criado no ataque, isto é, subgrafo composto pelos nós atacantes.

A partir de um grafo não-direcionado e um conjunto de nós a serem atacados, serão criados $\mathcal{O}(\log n)$ novos nós, isto é, nós atacantes. Cada atacante terá um identificador, que será $atacante_x$, sendo $0 \leq x \leq (atacantes - 1)$. As arestas entre os nós atacantes serão criadas de maneiras determinísticas e aleatórias, seguindo um padrão de regras definidas pelo ataque, de modo a facilitar a identificação desses atacantes no grafo anonimizado.

Além disso, cada nó atacado irá se conectar a um subconjunto único de nós atacantes, isto é, nenhum par de nós atacados irá estar conectado aos exatos mesmos nós atacantes. Assim, se for possível identificar os atacantes no grafo anonimizado, será possível identificar, por definição, todos os nós atacados. Como foi o promovedor do ataque quem criou as arestas entre os atacantes e os nós atacados, ele sabe exatamente qual nó atacado está conectado a cada subconjunto de atacantes. No final, basta encontrar um único nó no grafo anonimizada que esteja conectado à aquele exato subconjunto de atacantes, que já foi encontrado.

Por fim, é calculado um grau máximo para cada atacante, maior ou igual ao grau que ele já possui até o momento. Cada atacante irá se conectar a nós não atacados, até atingir seu grau máximo ou até não terem mais nós a se conectar: quando todos os nós do grafo são atacados, não existem nós não atacados para completar o grau dos atacantes. Este processo ocorre para aumentar a aleatoriedade do subgrafo criado.

A figura 1.1 representa um exemplo do ataque ocorrendo em um grafo anonimizado de 4 vértices, formado pelos nós azuis e cinzas, que representam nós atacados e não atacados, respectivamente. Os nós coloridos por rosa, por sua vez, são os nós atacantes, isto é, nós que foram adicionados ao grafo sendo atacado.




Figura 1.1: Exemplo de um grafo anonimizado após sofrer o ataque.

Para a recuperação do subgrafo criado, o atacante possui apenas a informação relativa aos nós e arestas que ele criou, uma vez que nas redes estudadas a informação estrutural da rede não é revelada. Este processo irá procurar, a partir dos conhecimentos que possui sobre a estrutura da rede, os nós atacantes em ordem. Isto é, o primeiro passo do processo é procurar pelo atacante 0, a partir de seu grau e do grau dos seus vizinhos à ele que são atacantes. Dessa forma, o algoritmo irá fazer uma varredura no grafo em busca de nós com o grau igual ao grau deste atacante e com uma sequência de grau dos vizinhos que contenha a sequência de graus dos vizinhos atacantes. Este processo é repetido para todos os nós atacantes, até identificar todos ou chegar à conclusão que não é possível fazer a identificação, resultando em falha.

A partir da maneira como os nós atacados foram relacionados aos nós atacantes, se for possível identificar todos os nós atacante na rede anonimizada, então será possível identificar todos os nós atacados. Como cada nó atacado está conectado ao a um subconjunto de nós atacantes diferentes e todos os nós atacantes foram identificados na rede, é possível a partir dessas informações identificar os nós atacados.

O algoritmo completo é apresentado detalhadamente no capítulo 3.

1.5 Estruturação do documento

No capítulo 2, veremos alguns trabalhos relacionados, isto é, trabalhos que também fizeram estudos ataques em grafos anonimizados e detecção dos mesmos. O capítulo 3 detalha o algoritmo proposto, bem como a tecnologia envolvida no desenvolvimento do mesmo. O capítulo 4 apresenta os resultados de diferentes execuções do método apresentado. O capítulo 5 apresenta uma técnica para detecção do ataque e analisa os resultados da mesma. Por fim, o capítulo 6 apresenta conclusões a respeito do trabalho e possíveis extensões e melhorias em trabalhos futuros.

Capítulo 2

Trabalhos Relacionados

Neste capítulo serão descritos alguns trabalhos relacionados. Isto é, trabalhos que também fizeram estudos ataques em grafos anonimizados e detecção dos mesmos.

2.1 *Anonymized social networks, hidden patterns, and structural steganography*

Este trabalho é detalhado em [2], sendo o principal objetivo descrever uma família de ataques que, mesmo a partir de uma única cópia de uma rede social anonimizada, tornam possíveis para o adversário aprender se existem relações entre usuários específicos. O trabalho desenvolvido por Lars e sua equipe foi a inspiração para este trabalho.

Três ataques diferentes são propostos e avaliados, sendo dois ativos e um passivo. Para isso, são considerados dados de redes sociais na forma mais pura, em que nós representam indivíduos e arestas indicam a interação social entre eles, de maneira não direcionada. Esses dados estão anonimizados, isto é, o identificador de cada usuário é trocado por um identificador aleatório.

Assim como no nosso trabalho, o trabalho de Lars sugere dois algoritmos diferentes para promover o ataque: a criação dos usuários atacantes, no caso dos ataques ativos, e a recuperação do subgrafo criado. A recuperação do subgrafo, também conhecida por identificação dos nós atacantes, utiliza a informação estrutural dos nós atacantes para encontrá-los no grafo anonimizado.

2.1.1 Ataque passivo

Neste ataque, usuários da rede são capazes de descobrir suas posições no grafo anonimizado usando o conhecimento que possuem sobre a estrutura local da rede em torno deles. Neste trabalho, os autores imaginaram uma pequena aliança formada

por atacantes passivos que se uniram para se identificar na rede anonimizada que foi divulgada. Ao fazerem isso, eles comprometem a privacidade de seus vizinhos: aqueles conectados a um subconjunto único de usuários que formam a aliança serão reconhecidos unicamente após a identificação dos usuários que formam a aliança que está realizando o ataque. Neste caso, os nós que formam a aliança compõem o subgrafo a ser encontrado no grafo anonimizado.

Uma aliança X de tamanho k é iniciada por um usuário que recruta $k - 1$ de seus vizinhos para se juntar à aliança. Os autores assumem que os usuários que formam a aliança conhecem as arestas entre eles, além de assumir que eles conhecem as identificações dos seus vizinhos que não estão presentes em X .

Resultados empíricos mostram que a aliança é facilmente encontrada no grafo anonimizado a partir da informação estrutural que ela possui, isto é, informações dos próprios nós que fazem parte da aliança, como grau. Entretanto, isto não significa que o algoritmo é capaz de identificar os demais usuários com certeza. Uma aliança de tamanho k não é capaz de comprometer mais do que $2 * k - 1$ usuários e, na prática, eles viram que o número é muito menor do que este. Isso se deve ao fato dos nós vizinhos à aliança não estarem conectados de maneira única aos nós que formam a aliança, de modo que mesmo após todos os nós atacantes terem sido reconhecidos ainda não ser possível identificar unicamente seus vizinhos.

2.1.2 Ataques ativos

Os ataques ativos descritos nesta subseção fazem uso de dois tipos de operação. Primeiro, o promotor do ataque pode criar novos usuários no sistema, adicionando novos nós ao grafo. Segundo, um nó u criado pelo atacante pode decidir se comunicar com o nó v , adicionando uma aresta não-direcionada (u,v) . O objetivo do ataque é escolher um conjunto arbitrário de usuários a serem atacados w_1, w_2, \dots, w_b e para cada par formado por esses nós descobrir se estão conectados, isto é, se existe aresta (w_i, w_j) .

Antes da rede anonimizada ser divulgada, o promotor do ataque cria k novos usuários e cria arestas entre eles para criar um subgrafo H . O próximo passo é utilizar essas novas contas criadas para criar conexões com os nós pertencentes à w_1, \dots, w_b . O promotor do ataque encontra a cópia de H no grafo anonimizado e a partir disto identifica os nós w_1, \dots, w_b . Se o promotor do ataque tiver identificado corretamente todos os nós atacados, então ele é capaz de revelar as relações entre eles.

É importante ressaltar que o subgrafo H criado é gerado pelo atacante sem que ele conheça o grafo sendo atacado, o que dificulta o processo, uma vez que ele precisa criar um subgrafo que seja identificado de maneira única. Isto é, o subgrafo

não pode possuir isomorfismos com nenhum outro subgrafo gerado a partir do grafo anonimizado e nenhum automorfismo. Esses conceitos são discutidos mais a frente, no capítulo 3.

Dois ataques são descritos nesta subseção do artigo. Para o primeiro, os autores mostram que para $k = \theta(\log n)$ novos usuários, um subgrafo H gerado aleatoriamente será único com alta probabilidade, independentemente das propriedades estruturais de G , grafo anonimizado, e de como H é anexado a G . Além disso, se o grau máximo de H for $\theta(\log n)$, então H é recuperado eficientemente, junto da identificação dos nós atacados, sendo $b = \theta(\log^2 n)$. Este ataque é capaz de comprometer a privacidade de $\theta(k^2)$ usuários. O segundo ataque é similar ao primeiro, porém possui diferenças na maneira como o subgrafo H é anexado ao grafo G original, uma vez que usa menos arestas para conectá-los. A fina ligação entre H e o resto de G implica que o subgrafo criado provavelmente será único e eficientemente encontrado em um valor assintoticamente menor de k : este ataque utiliza $k = \mathcal{O}(\log n)$ para revelar a identidade de $\mathcal{O}(\sqrt{\log n})$.

No trabalho de Lars é provado que os algoritmos de ataque ativo irão funcionar, com alta probabilidade, desde que não existam automorfismos não triviais no subgrafo H criado.

O ataque proposto por este trabalho, por sua vez, tem como objetivo criar $\mathcal{O}(\log n)$ novos usuários e ser capaz de revelar a identidade de $\mathcal{O}(n)$.

2.2 Resisting structural re-identification in anonymized social networks

Este trabalho é detalhado em [3], em que os autores identificam riscos de privacidade associados a liberação de conjuntos de dados de uma rede e fornecem um algoritmo que mitigue esses riscos. Manter a privacidade ao publicar um conjunto de dados de rede é excepcionalmente desafiador porque o contexto da rede de um indivíduo pode ser usado para identificá-los, mesmo que outras informações de identificação sejam removidas. No nosso trabalho, utilizamos informações estruturais da rede, adicionadas pelo promotor do ataque, para identificar nós de uma rede anonimizada.

O foco deste artigo é analisar os resultados de divulgações resultantes da re-identificação estrutural ou topológica, em que a informação do adversário é apenas sobre a estrutura do grafo. Além disso, ele fornece uma avaliação abrangente dos riscos de privacidade da anonimização ingênua, que os autores descrevem como apenas omitir a identificação de cada usuário ao divulgar uma rede.

A partir da anonimização ingênua, o trabalho propõe um modelo adversário baseado nas assinaturas estruturais, que se baseia em uma classe de consultas de

conhecimento, de poder crescente, que relata a estrutura local do grafo em torno de um nó. Essas consultas são inspiradas pelo refinamento iterativo de vértices [4]. Essas consultas são denotadas por H_i , em que H_0 retorna a identificação do nó (em grafos anonimizados, não retorna nada). $H_1(x)$ retorna o grau do nó x , $H_2(x)$ retorna a sequência de grau dos vizinhos de x e assim por diante. As consultas podem ser definidas iterativamente, em que $H_i(x)$ retorna os conjuntos de valores que são o resultado da avaliação de H_{i-1} no conjunto de nós adjacentes à x . O trabalho presente utiliza as consultas H_1 e H_2 para fazer o reconhecimento dos nós adicionados ao grafo atacado.

Os autores definem um conjunto de candidatos a partir de uma consulta H_i . Este conjunto é formado por todos os nós do grafo que possuem o mesmo valor H_i . Por exemplo, no caso de H_1 , todos os nós com mesmo grau ficam no mesmo conjunto. A ideia é que nós em um mesmo conjunto são irreconhecíveis de acordo com H_i , de modo a precisar de mais informações para tentar identificar esses nós. É analisado, para 7 redes, reais e geradas a partir de modelos matemáticos, a quantidade de nós identificados a partir de H_1 , H_2 , H_3 e H_4 . Como quanto maior o índice da consulta feita, mais informações o atacante possui sobre a rede, a probabilidade de identificar um nó corretamente cresce de H_1 para H_2 , de H_2 para H_3 e assim por diante.

Automorfismos, que são detalhados no capítulo 3 deste trabalho, fornecem segurança contra ataques como este, uma vez que a identificação única de alguns nós se torna impossível. O trabalho analisa que na maior parte das redes esperamos encontrar classes de automorfismos pequenas, de modo a não ser suficiente para proteger ataques deste tipo.

O artigo encontra que o fator crítico que determina o risco de re-identificação em grandes grafos aleatórios, gerados a partir de modelos matemáticos, é a densidade (a fração das arestas que existem no grafo sobre todas as possíveis arestas que poderiam existir). Grafos esparsos (com densidade baixa) têm baixo risco de re-identificação estrutural, enquanto os grafos densos têm alto risco.

Além disso, uma técnica de anonimização é proposta para proteger grafos contra ataques de re-identificação a partir de sua estrutura. O grafo é generalizado a partir do agrupamento de nós em partições. Ao em vez de divulgar o grafo anonimizado que representa exatamente a estrutura da rede em questão, se é publicado o número de nós em cada partição juntamente com a densidade de arestas que existem dentro e entre as partições. Desta forma, o adversário tenta fazer a re-identificação, sem sucesso, enquanto o analista utiliza o grafo para estudar as propriedades do grafo original. Um algoritmo, chamado de GraphGen, é proposto, em que dois parâmetros são passados: o grafo original e um valor número representado pela letra k . O grafo anonimizado possuirá super nós, também chamado de partições, com pelo menos k nós da rede original. É também proposta uma extensão a este algoritmo, sendo

a ideia apenas anonimizar nós vulneráveis a re-identificação, de modo a preservar mais a estrutura da rede. É feita uma avaliação extensa dos algoritmos propostos.

Capítulo 3

Algoritmo proposto

3.1 Explicação detalhada

A explicação em alto nível já foi feita no capítulo de introdução. Em cada subseção a seguir, um componente específico será explicado detalhadamente.

3.1.1 Criação dos atacantes

Este processo recebe como entrada o grafo original a ser atacado e os nós específicos a serem atacados. O número de nós atacados pode variar entre um e todos os nós do grafo.

Número de atacantes criados

Conforme explicado sucintamente na introdução, cada nó atacado irá se conectar a um subconjunto de nós atacantes único, de tamanho maior igual a 2. Cada nó atacado precisa, obrigatoriamente, estar conectado a um subconjunto diferente de nós atacantes, uma vez que o processo de identificação desses nós na rede anonimizada será feito por meio do reconhecimento dos nós atacantes. Dessa forma, se for possível reconhecer os nós criados de forma intencional na rede, será possível reconhecer todos os nós atacados, uma vez que o atacante sabe exatamente as relações existentes entre esses dois grupos de nós.

O tamanho mínimo de cada subconjunto de nós atacantes ser igual a dois é outra premissa definida pelo método. De modo a tornar o subgrafo de atacantes criado mais aleatório e evitar a presença de isomorfismos entre o subgrafo de atacantes e o grafo formado pela rede inicial somada ao subgrafo criado, o processo cria arestas entre nós não atacados, se existirem, e nós atacantes. Para isso, é preciso que os nós não atacados possuam subconjuntos de atacantes diferentes à todos os subconjuntos relacionados aos nós atacados, para não confundir um nó atacado a um não atacado. Dessa forma, o modelo proposto define que os nós não atacados só podem se conectar

a um nó atacante, isto é, o subconjunto de nós atacantes possui tamanho igual a 1. O objetivo desta prática é diminuir a complexidade do algoritmo, ao evitar que ele precise procurar por subconjuntos de atacantes que não estejam conectados aos nós atacados.

Sendo assim, o número mínimo de subconjuntos de atacantes de tamanho maior igual a 2 necessários é igual ao número de nós atacados. Para calcular o número de nós atacantes, isto é, nós a serem criados, será utilizado o cálculo descrito abaixo. X representa o número de nós atacantes, o valor a ser calculado, e Y o número de nós atacados, valor de entrada do processo, determinado pelo atacante.

Para gerar todos os possíveis subconjuntos a partir de X nós atacantes, basta elevar 2 a X : cada atacante pode estar no subconjunto ou não, sendo duas possibilidades, resultando em 2^X . Como os subconjuntos precisam ter tamanho maior igual a 2, é necessário remover os subconjuntos de tamanho igual a 1 (existem X subconjuntos nesse caso) e o subconjunto com tamanho igual a 0, isto é, aquele que não possui nenhum atacante, e só possui 1 subconjunto que representa este caso.

$$Y = 2^X - 1 - X$$

O número de nós atacados, Y , varia entre 0 e n , isto é, $0 \leq Y \leq n$, sendo n o número de nós no grafo. Para o cálculo de número de nós atacantes, o pior caso será utilizado, isto é, quando o atacante deseja atacar o grafo inteiro, $Y = n$.

Logo, considerando que o número mínimo de diferentes subconjuntos de atacantes de tamanho maior igual a dois é igual a $2^X - 1 - X$, temos:

$$n \leq 2^X - 1 - X$$

Sabendo que n e X são números inteiros positivos:

$$n \leq 2^X - 1 - X < 2^X$$

$$n < 2^X$$

$$X > \log_2 n$$

O propósito do processo é não precisarmos criar muitos atacantes para conseguir que o ataque seja sucedido. Conhecendo o limitante inferior, o objetivo será encontrar um limitante superior que não faça com que o número de atacantes seja um número alto quando comparada ao número de nós do grafo. Sabendo que um número em função de $\mathcal{O}(\log n)$ é ordens de grandeza menor que um número n , o objetivo será encontrar um limitante superior que possua essa complexidade. Ou seja, encontrar um valor para X , inteiro e positivo, que seja $\log_2 n$ multiplicado por uma constante c :

$$X \leq c * \log_2 n$$

$$X \leq c * \log_2(2^X - 1 - X) < c * \log_2(2^X)$$

$$X < c * \log_2(2^X)$$

$$X < c * X$$

$$0 < (c * X) - X$$

Consequentemente: $c > 1$

Neste trabalho, será utilizado $c = 2$. Logo, o número de nós atacantes, X , será igual a duas vezes o log na base dois do número de nós do grafo, isto é:

$$X = 2 * \log_2 n$$

Logo, serão criados $2 * \log_2 n$ novos usuários, os quais o promotor do ataque terá informações estruturais sobre, uma vez que ele quem criou esses nós.

Criação das arestas

Para o ataque funcionar, precisamos encontrar o subgrafo de atacantes criado no grafo anonimizado a ser divulgado. Portanto, este subgrafo será criado com propriedades específicas, de modo a tentar se sobressair do restante da rede. Como o algoritmo não conhece o grafo que está atacando, o subgrafo gerado possuirá sempre as mesmas propriedades.

1. Criação das arestas entre os atacantes

- (a) Toda aresta do tipo $(atacante_i, atacante_{i+1})$ será criada, isto é, o $atacante_0$ estará ligado ao $atacante_1$, o $atacante_1$ estará ligado ao $atacante_2$ e assim por diante, fechando um ciclo entre todos os atacantes, uma vez que a aresta $(atacante_0, atacante_{X-1})$ também é criada, sendo X o número de atacantes.




Figura 3.1: Exemplo do subgrafo de atacantes após adição inicial de arestas.

- (b) As demais arestas serão criados aleatoriamente: cada par de nós ($atacante_i, atacante_j$), sendo $i < (j + 1)$ terá uma aresta os conectando com probabilidade $1/2$.




Figura 3.2: Exemplo do subgrafo de atacantes após adição de todas as arestas entre os atacantes.

2. Em seguida, as arestas entre os nós atacantes e os nós atacados são adicionadas. Ao final deste passo, todos os nós atacados precisam estar conectados à um subconjunto único de nós atacantes de tamanho maior igual a dois.

Para gerar os subconjuntos de atacantes de tamanho maior igual a dois associados a cada nó atacado, foi criado um vetor de booleanos de tamanho igual ao número de atacantes, que será chamado de vetor de marcação. Cada posição do vetor só pode assumir dois valores: 0 (falso) ou 1 (verdadeiro). Esse vetor é inicializados com todas as posições contendo o valor 0.

Para cada nó atacado, o processo verifica se o vetor de marcação possui pelo menos duas posições preenchidas com o valor 1. Se possuir: para cada posição que estiver com o valor 1, uma aresta é criada entre o atacante correspondente (índice no vetor de onde está o valor 1). Em seguida, o vetor é transformado

em um número binário de 0's e 1's e é adicionado 1 unidade binário à esse número, que é então transformado em um vetor de marcação novamente. Caso não possua pelo menos duas posições com o valor 1, apenas a soma binária acontece. Esse processo é repetido até cada nó atacado. A transformação entre vetor de booleanos e número binário é feita da maneira como se segue neste exemplo: vetor $[1,0,1,0,1]$ se transforma no número 10101.

Dessa forma, é garantido que todo nó atacado estará conectado a pelo menos dois atacantes e que nenhum outro nó atacado estará conectado à exatamente os mesmos nós atacantes.

A tabela 3.1 representa o vetor de marcação em um exemplo ao longo de algumas iterações. Cada coluna representa uma posição do vetor: como existem 4 atacantes, o vetor possui tamanho igual a 4 e cada posição do vetor está associada a um atacante. Por exemplo, a posição 0 do vetor está associada ao *atacante*₀, e assim por diante.

Para fins demonstrativos, apenas as iterações iniciais são mostradas na tabela. Para cada nó atacado, o objetivo é encontrar um vetor de marcação com mais de uma posição preenchida com o valor verdadeiro. Logo, o processo é iniciado com o nó atacado 1. Nas iterações 1,2 e 3 apenas a soma binária de uma unidade acontece, pois não existem posições suficientes com o valor 1. Na iteração 4, entretanto, existem, de modo que o nó atacado 1 é conectado, portanto, ao *atacante*₂ e ao *atacante*₃. Em seguida, passamos para o próximo nó atacado, nó atacado 2, e a soma binária acontece. Na iteração 5 apenas a soma acontece e na 6 o nó atacado 2 é conectado aos nós *atacante*₁ e *atacante*₃. O processo continua até todos os nós atacados terem se conectado aos atacantes dessa forma.

Tabela 3.1: Vetor de marcação de atacantes a cada iteração, com 4 atacantes.

Iteração	0	1	2	3
1	0	0	0	0
2	0	0	0	1
3	0	0	1	0
4	0	0	1	1
5	0	1	0	0
6	0	1	0	1

3. Por fim, o algoritmo tenta criar arestas entre os atacantes e os nós não atacados, sendo nós não atacados nós do grafo original que não foram escolhidos pelo promotor do ataque para terem sua privacidade violada. Esse processo é feito de modo a aumentar a aleatoriedade do subgrafo criado e diminuir as chances de encontrar um isomorfismo dele no grafo. Essa parte será discutida detalhadamente mais a frente.

Neste passo, é importante diferenciar os conceito de graus internos e externos do atacante: grau interno é a quantidade de nós atacantes ao qual um nó atacante está relacionado e grau externo é a quantidade de nós não atacantes, isto é, nós da rede inicial, ao qual um nó atacante está relacionado. A soma dessas duas métricas origina o grau de cada nó atacante.

Para cada nó atacante, um grau externo máximo é gerado a partir de uma distribuição uniforme entre o grau externo que o nó possui até o momento, isto é, a quantidade de nós atacados aos quais ele está conectado, e um número representado pela letra d . O valor de d varia de acordo com o grau externo do nó até o momento: se o grau externo for igual a zero, isto é, aquele atacante não está conectado a nenhum nó da rede inicial, então d é igual ao número de atacantes ($\mathcal{O}(\log n)$). Caso contrário, d segue a seguinte fórmula:

$$((rand() \pmod{X}) + 1) * ((rand() \pmod{X}) + 1) + grauExterno$$

, em que $grauExterno$ é o grau externo do nó em questão, X é o número de nós atacantes e $rand()$ é a função de c++ que retorna um número aleatório. Essa função aleatório foi inicializada com a semente sendo igual a X .

Após cada atacante receber um grau máximo externo maior do que o grau externo que ele possui até o momento, o próximo passo é tentar criar relações entre nós atacantes e não atacados. É necessário, porém, apenas conectar nós não atacados a subconjuntos de atacantes diferentes aos subconjuntos gerados para os nós atacados, de modo a não confundir, no processo de reconhecimento no grafo anonimizado, um nó atacado e um não atacado. Para facilitar esse processo e acelerá-lo, uma vez que não será necessário verificar quais subconjuntos já foram usados, o método só associa nós não atacados a subconjuntos de atacantes de tamanho igual a um.

É necessário, aqui, gerar uma lista com todos os nós não atacados. Cada nó dessa lista só poderá ser conectado a um nó atacante, respeitando a regra definida no parágrafo acima. Assim sendo, para cada nó atacante, enquanto ele não tiver atingido seu grau máximo externo e o tamanho da lista de nós não atacados for maior que zero, o algoritmo escolhe aleatoriamente um nó não

atacado da lista, o removendo da lista, e o associa ao atacante em questão, aumentando em uma unidade seu grau externo. Esse processo é repetido para todos os nós atacantes até conseguir alcançar todos os graus máximos externos gerados ou não existirem mais nós não atacados na lista. No caso do promotor do ataque decidir atacar todos os nós da rede, por exemplo, não existem nós não atacados.

Verificação de Automorfismos

Por fim, antes de escrever os arquivos de saída, o algoritmo faz uma busca simples para verificar a possível existência de automorfismos no subgrafo de atacantes criado. Não é possível afirmar, entretanto, se existem automorfismos, pois seria necessário conhecer toda a estrutura da rede formada após os passos acima, como grau de todos os nós da rede, o que não temos. O atacante só possui a informação de grau dos nós que ele mesmo adicionou, então essas informações serão usadas para verificar se existem automorfismos que o algoritmo é capaz de identificar. Se o algoritmo identificar um possível automorfismo, então todo o processo descrito nesta subseção é refeito. Existe um número de tentativas máximas por execução, de modo a evitar possíveis, porém improváveis dada a descrição do processo, infinitas iterações.

- É necessário, portanto, ter duas definições que serão muito usadas ao longo deste trabalho:

1. Automorfismo: segundo [5], um automorfismo de um grafo é uma forma de simetria em que o grafo é mapeado em si, preservando a conectividade vértice-aresta. Formalmente, um automorfismo de um grafo $G = (V, E)$ é uma permutação σ do conjunto de vértices V , tal que para qualquer aresta $e = (u, v)$, $\sigma(e) = (\sigma(u), \sigma(v))$ é também uma aresta. Ou seja, ele é um isomorfismo de grafos de G para ele mesmo.

A figura 3.3 representa um grafo que contém automorfismo. A partir da estrutura da rede, nenhum algoritmo é capaz de diferenciar os nós.




Figura 3.3: Automorfismo em grafo.

2. Isomorfismo: de acordo com [6], um isomorfismo dos grafos G e H é uma bijeção entre os conjuntos de vértices de G e H $f: V(G) \rightarrow V(H)$ de tal forma que quaisquer dois vértices u e v de G são adjacentes em G se e somente se $f(u)$ e $f(v)$ são adjacentes em H . Este tipo de bijeção é comumente chamado de "bijeção com preservação de arestas", de acordo com a noção geral de isomorfismo sendo uma bijeção de preservação-de-estrutura.

A figura abaixo representa um exemplo de isomorfismo entre dois grafos.




Figura 3.4: Isomorfismo em grafos.

Para o processo final, de identificação dos nós atacados ou reconhecimento do subgrafo de atacantes, funcionar, o subgrafo de atacantes criado não pode possuir automorfismos ou isomorfismos com qualquer outro subgrafo possível no grafo final, resultante do grafo inicial depois de passar pela criação dos nós e das arestas provenientes do ataque. Caso existisse, não seria possível identificar, com certeza, todos os nós atacados no grafo anonimizado. Como os nós atacados são identificados a partir de suas relações com os nós atacantes, não seria possível identificá-los.

Não é possível, durante a criação dos atacantes, identificar isomorfismos entre o subgrafo criado e qualquer subgrafo formado a partir da rede completa, uma vez que a estrutura do grafo inicial é desconhecida. Isto é, um isomorfismo entre qualquer subgrafo da rede e o subgrafo de atacantes significaria confundir pelo menos um atacante a um não atacante. Como não temos qualquer informação estrutural sobre os não atacantes, e o reconhecimento de isomorfismos depende dessa informação, não é possível procurar por isomorfismos neste componente.

Pelo mesmo motivo, também não é possível afirmar se existem ou não automorfismos. Porém, podemos procurar por possíveis automorfismos, de modo a tentar evitá-los.

Supondo que toda a estrutura da rede fosse conhecida, o problema para encontrar

automorfismos em um grafo é um problema NP-completo. O processo criado neste trabalho para procurar por possíveis automorfismos, pelo contrário, possui uma complexidade polinomial e foi inspirada na ideia proposta em [3]: utilizar o grau de cada nó e a sequência de grau dos vizinhos de cada nó.

Desse modo, a ideia consiste em utilizarmos todas as informações que o promotor do ataque possui sobre a estrutura da rede, isto é, a informação que ele mesmo adicionou: o grau de cada nó atacante. Utilizando essa informação, também é possível pensar na sequência de grau dos vizinhos de cada atacante, para os vizinhos que forem também atacantes, uma vez que não temos informação de grau sobre os demais vizinhos.

Uma condição necessária para existir um automorfismo é: dois nós possuem o mesmo grau, caso contrário eles jamais seriam confundidos a partir de sua estrutura. Outra condição necessária, que só é analisada caso a primeira condição seja verdadeira, é que a sequência de grau dos vizinhos desses dois nós deve ser igual. Porém, o processo não tem acesso à sequência de grau dos vizinhos completa de cada nó atacante, ele tem apenas uma parte dela, que são os graus dos vizinhos que são atacantes. Sendo assim, a condição, neste trabalho, é ter dois nós atacantes com o mesmo grau e a sequência de um deles estar contida na do outro. Ambas condições descritas neste parágrafo são necessárias, porém não suficientes.

Para exemplificar a segunda condição descrita, suponha dois nós atacantes, com valor de grau igual a 5. O primeiro nó, *atacante₀* está conectado a três atacantes e dois atacados, de modo que a sua sequência de grau dos vizinhos possua tamanho três e seja, por exemplo, igual a [1,2,3]. O segundo nó, *atacante₁*, por sua vez, está conectado a quatro atacantes e um atacado, sendo a sequência de grau dos vizinhos conhecida dele igual a [1,2,3,4]. Para finalizar, suponha que o grau dos nós atacados conectados à esses dois atacantes seja igual a 4. Dessa forma, as duas sequências de grau dos atacantes fica igual, podendo ocorrer uma confusão entre esses dois nós no grafo anonimizado e, conseqüentemente, um automorfismo.

O algoritmo, por sua vez, cria um dicionário, em que a chave é um número, o grau do nó, e o valor é uma lista de sequências de graus de vizinhos. Para cada atacante, gera-se a sequência de graus dos seus vizinhos atacantes e verifica se para o grau deste atacante já existe uma sequência igual a dele, que contenha a dele ou que ele contém. Se não existir, adiciona a sequência no dicionário na lista que possui o grau dele como chave e vai para o próximo atacante. Caso exista, o processo acusa um possível automorfismo, e, se ele não tiver tentado gerar um subgrafo de atacantes mais vezes do que o limite estipulado, todo o processo descrito nesta seção é repetido.

Vale ressaltar que a acusação de um possível automorfismo não significa que obrigatoriamente vá existir um automorfismo, uma vez que apenas uma parte da

sequência de grau dos vizinhos não é suficiente para afirmar a existência de um automorfismo. Dessa forma, esse processo analisa uma condição necessária, porém não suficiente.

A complexidade deste processo varia com o número de atacantes, igual a X , e o número de vizinhos de cada atacante. No pior caso, um atacante está conectado ao grafo inteiro e a todos os nós atacantes, isto é, $n + X - 1$, sendo n o número de nós do grafo inicial. Como $X = 2 * \log_2 n$, a complexidade é igual a $\mathcal{O}((\log_2 n) * (n + \log_2 n))$, que é igual a $\mathcal{O}(n * (\log_2 n))$

Arquivos de Saída

Por fim, existem dois arquivos que são gerados a partir deste processo e são utilizados nos próximos: o grafo inicial com os novos usuários e arestas, criados por este componente, e um arquivo com as informações estruturais dos atacantes, isto é, o grau de cada atacante e a sequência de graus dos vizinhos dele que são atacantes.

3.1.2 Anonimização do grafo

A proposta deste trabalho é identificar nós escolhidos pelo promotor do ataque, também chamados de nós atacados, de modo a revelar relações entre eles. Para ser possível analisar a eficiência do algoritmo proposto, isto é, se o mesmo é capaz de identificar os nós atacados ou não, é necessário conhecer a identificação de cada nó na rede, de modo que seja possível comparar o resultado encontrado para cada nó com a informação original.

Para isso, este componente fará a anonimização do grafo, de modo a simular o processo que a empresa detentora da rede a ser divulgada faria antes de liberar os dados.

Esse processo recebe como entrada a rede gerada pelo processo anterior, isto é, a união entre rede inicial e o subgrafo de nós atacantes criado, que engloba também todas as relações entre esses nós e os da rede inicial. A saída dele, por sua vez, são dois arquivos: a rede anonimizada, isto é, a mesma estrutura rede de entrada, porém com os identificadores anonimizados que foram gerados; o mapeamento de cada nó, ou seja, um mapa entre a identificação que cada nó possuía na rede de entrada e o novo identificador anônimo gerado. Este arquivo será utilizado para analisar a eficiência do método no final, ao tentar identificar os nós atacados, comparando a identificação encontrada para cada nó com a identificação real.

- Para a geração dos identificadores, todos os identificadores reais de cada nó são dispostos em uma lista e existem duas opções para gerar a troca de identidade:

1. Cada nó recebe um identificador aleatório, que será o índice do seu identificador real na lista com todos os identificadores
2. Cada nó recebe o identificador de outro nó, isto é, ocorre uma permutação entre os identificadores existentes.

Para exemplificar, a figura 3.5 representa um grafo com 5 nós e arestas não-direcionadas entre eles, a figura 3.6 representa o grafo anonimizado a partir da técnica 1 descrita acima e a figura 3.7 representa o grafo anonimizado a partir da técnica 2.




Figura 3.5: Grafo para exemplificar componente de anonimização.

Como este processo é aleatório, diferentes execuções com os mesmos parâmetros podem gerar arquivos de saída diferentes. A fim de exemplificação, as tabelas abaixo representam possíveis resultados extraídos do algoritmo de acordo com a geração dos identificadores:

Tabela 3.2: Resultados do processo de anonimização a partir do índice de cada nó

Identificador Real	Identificador Anonimizado
2	4
3	2

Tabela 3.2 – continuação

Identificador Real	Identificador Anonimizado
4	0
1	3
5	1




Figura 3.6: Grafo anonimizado pelo processo de anonimização a partir do índice de cada nó.

Tabela 3.3: Tabela representando resultados do processo de anonimização a partir da permutação entre os identificadores

Identificador Real	Identificador Anonimizado
4	5
3	3
2	4
1	2
5	1




Figura 3.7: Grafo anonimizado pelo processo de anonimização a partir da permutação entre os identificadores.

3.1.3 Recuperação do subgrafo

O objetivo deste componente é encontrar o subgrafo de atacantes criado no componente Criação de Atacantes. Pela definição do algoritmo, se for possível identificar todos os atacantes, então todos os nós atacados, que foram os nós definidos pelo promovedor do ataque para terem sua privacidade revelada, serão identificados. Consequentemente, relações entre nós atacados também serão reveladas.

Este componente recebe de entrada os seguintes arquivos: o grafo anonimizado, gerado no processo de anonimização do grafo descrito; o arquivo contendo a informação de cada atacante, isto é, informação de grau e sequência de grau dos vizinhos que são atacantes; o subgrafo de atacantes criado, isto é, todas as relações a partir dos atacantes criados; o arquivo que mapeia o identificador real de cada nó para o identificador anonimizado. A função de cada arquivo será descrita ao longo desta subseção.

O primeiro passo é carregar todas as informações passadas por arquivos de texto para memória, em estruturas de dados eficientes para o propósito de cada informação.

Em seguida, este componente irá procurar, no grafo anonimizado, pelos nós atacantes, que são aqueles que temos alguma informação estrutural sobre. Para

isso, o processo irá procurar em ordem pelos atacantes, isto é, irá procurar pelo *atacante*₀, depois pelo *atacante*₁ e assim por diante.

De modo a encontrar os nós atacantes, o processo irá utilizar uma lista de árvores.

Para encontrar o *atacante*₀, o processo passa por todos os nós do grafo anonimizado e analisa quais nós possuem o mesmo grau que o atacante sendo buscado. Para os que tiverem o mesmo grau, o processo então analisa a sequência de grau dos vizinhos desse nó. Como só temos parte da sequência de grau dos vizinhos, uma vez que só temos os graus dos vizinhos à este atacante que também são atacantes, é necessário verificar se a sequência de grau dos vizinhos do atacante está contida na sequência de grau dos vizinhos do nó anonimizado que possui o mesmo grau que o *atacante*₀. Se isso acontecer, então uma árvore é criada e adicionada à lista, em que este nó anonimizado será a raiz. Este processo é repetido até verificar todos os nós anonimizados.

Para os demais nós atacantes, o algoritmo irá passar por cada árvore e, nestas, irá trabalhar com cada nó folha. A altura da árvore determina o atacante que o nó anonimizado pode ser. Por exemplo, o nó na raiz, que está na altura 0, é um possível *atacante*₀.

Dessa forma, para cada atacante (diferente do *atacante*₀), para cada árvore, para cada nó folha, o algoritmo irá buscar por todos os vizinhos do nó folha sendo trabalhado e procurar, utilizando o mesmo procedimento descrito para identificar o *atacante*₀, o próximo atacante. Isto é, se o nó folha está representando um possível *atacante*_x, então o algoritmo irá procurar dentre todos os vizinhos deste nó o *atacante*_{x+1}, lembrando que de acordo com a maneira que os atacantes foram criados, todo *atacante*_x está conectado ao *atacante*_{x+1}.

A figura 3.8 é um exemplo de possíveis árvores gerada após 3 iterações de busca por atacantes. Existem dois possíveis nós para serem o *atacante*₀, B e G, que possuem o mesmo grau deste atacante e a sequência de grau dos vizinhos atacantes do atacante está contida na sequência de grau dos vizinhos de B e G, existem quatro possíveis nós para o *atacante*₁, (D,A,E,H), e apenas um nó para ser o *atacante*₂. Após o final da segunda iteração, existem 2 árvores e 2 nós folhas em casa. Assim, na terceira iteração, o processo busca pelo *atacante*₂ nos vizinhos de (D,A,E,H), só encontrando um possível vizinho de A que tivesse as condições necessárias. Vale ressaltar que (A,B,C,D,E,F,G,H) são identificadores anonimizados de cada nó.




Figura 3.8: Árvore exemplificando a recuperação dos atacantes no grafo anonimizado.

O processo de busca pelos atacantes continua até uma das seguintes situações acontecerem: todos os possíveis nós para atacantes foram encontrados, isto é, existe pelo menos uma árvore com altura igual a $X - 1$, sendo X igual ao número de atacantes (considerando que a altura da árvore começa em zero); a soma de nós folhas em todas as árvores ultrapassar um limite estipulado pelo promotor do atacante. Isto acontece para que o processo não gere milhares e milhares de possíveis subgrafos de atacantes, o que ocorre quando existem muitos automorfismos ou isomorfismos no grafo anonimizado.

Se durante uma iteração um nó folha representando um possível $atacante_x$ não encontrar em seus vizinhos um possível $atacante_{x+1}$, o nó folha em questão é apagado, uma vez que ele não pode representar o $atacante_x$ já que por definição ele está conectado ao $atacante_{x+1}$. Uma vez apagado este nó folha, o algoritmo analisa se o pai deste nó virou folha. Se sim, ele também é apagado e o processo continua subindo na árvore para o pai deste, até encontrar um nó não folha ou a raiz. Caso contrário, nada é feito a mais neste passo e o processo continua normalmente. Deste modo, ao final de cada iteração, só existem nós folhas na altura da iteração - 1, que representa o número do atacante sendo procurado.

Uma vez que o processo tenha terminado, por qualquer dos motivos citados acima, o próximo passo é analisar se o algoritmo foi sucedido ou não.

Sucesso do Algoritmo

O algoritmo terá sido bem sucedido se ao final da execução do processo descrito acima ele encontrar uma única árvore, de altura igual ao número de atacantes - 1 (lembrando que estamos considerando que a altura inicial da árvore é igual a 0), com número de nós igual ao número de atacantes. Isto é, seria um grafo linha com X nós, sendo X o número de nós atacantes, em que cada nó representa um nó atacante em ordem: a raiz representa o $atacante_0$, o nó conectado à raiz representa o $atacante_1$ e assim por diante. Se isso acontecer, então o processo funcionou e todos os nós

atacados e as relações entre eles podem ser identificadas. Caso contrário, o processo falhou.




Figura 3.9: Árvore representando o sucesso na recuperação dos atacantes no grafo anonimizado.

Falha do Algoritmo

O algoritmo falha se ele não for capaz de identificar todos os atacantes no grafo anonimizado, isto é, se a árvore gerada, no final do processo, não representar um grafo linha com número de nós igual ao número de atacantes.

- Só existem dois possíveis motivos para o processo falhar:
 1. Apesar da aleatoriedade do processo, ainda ocorreu pelo menos um isomorfismo entre o subgrafo formado pelos nós atacantes e um subgrafo qualquer presente no grafo anonimizado. Dessa forma, um ou mais nós não atacantes são confundidos com nós atacantes.
 2. Automorfismo não identificado do subgrafo, isto é, não é possível diferenciar um par ou mais de atacantes. Por exemplo, dado um nó qualquer do grafo anonimizado, pelas informações que o processo possui, ele pode ser tanto o *atacante₀* quanto o *atacante₁*. Apesar do processo de criação de nós e arestas procurar por automorfismos e evitá-los, ele não conhece a estrutura do restante da rede, de modo que ele não é capaz de evitar por completo a existência de automorfismos.

Para exemplificar o caso em que o processo de verificação de automorfismos não é capaz de acusar um possível automorfismo, vamos supor dois

nós atacantes, com o mesmo grau e o mesmo número de atacantes conectados à ele (mesmo tamanho da sequência de graus dos vizinhos que são atacantes). Porém, as sequências não são iguais: de um é $[1,2,3]$ e de outro é $[1,2,4]$, ou seja, o algoritmo descrito não é capaz de identificar um automorfismo aqui. Agora, por exemplo, vamos supor que o primeiro está conectado a um nó atacado de grau 4 e o segundo está conectado a um nó atacado de grau 3, informações que o ataque não possui. Logo, na busca pelo atacante anonimizado no grafo, existem dois nós com a mesma sequência de grau dos vizinhos $[1,2,3,4]$, podendo caracterizar um automorfismo não identificado pelo processo. Apenas isso não é suficiente para afirmar que existirá um automorfismo, dado que as informações dos nós vizinhos a cada um ele também importam, mas é um indicador de um possível automorfismo.

Existe, entretanto, uma outra possibilidade para a presença de um automorfismo: o processo de verificação de automorfismos funciona, de modo a refazer todo o processo de criação de nós atacantes e suas arestas. Porém, existe um número máximo de vezes, escolhido pelo promotor do ataque, que o processo é capaz de refazer tudo. Se o processo gerar mais possíveis automorfismos identificáveis do que o número máximo de vezes permitido, então o processo de recuperação do subgrafo poderá falhar, uma vez que o processo de criação dos atacantes foi concluído com um subgrafo de atacantes com um possível automorfismo detectado.

Por fim, o processo utiliza o mapeamento de cada identificador real para o identificador anônimo para verificar o motivo da falha, isto é, verificar se o problema foi um isomorfismo ou um automorfismo.

3.2 Implementação

Os algoritmos descritos neste capítulo foram implementados na linguagem de programação c++ e nenhuma biblioteca externa foi utilizada.

Como nenhum algoritmo complexo de grafos foi utilizado, não foi utilizada uma biblioteca externa para a representação de grafos. Apenas estruturas nativas da linguagem, como *unordered map*, *unordered set*, listas e dicionários foram utilizados para o armazenamento eficiente das informações sobre os nós e suas relações. Cada processo utiliza as estruturas que melhor funcionam para si, isto é, que diminuem a complexidade de execução do algoritmo. Por exemplo, se a ideia é fazer muito acesso à uma lista, o *unordered set* possui uma complexidade de busca melhor de que a de um vetor.

A cada execução do algoritmo os grafos são passados como arquivos de texto, em que cada linha possui dois identificadores, separados por espaço, que representa uma aresta relacionando esses dois nós representados. Os grafos são então salvos em memória e os algoritmos são executados.

Para a automatização dos testes, *scripts* foram desenvolvidos na linguagem *shell script*, de modo a facilitar a execução de diferentes grafos. Esses *scripts* executam os três processos descritos acima de maneira sequencial, em que a saída de um dos componentes é a entrada do próximo.

Por fim, *scripts* em python também foram desenvolvidos para a realização de algumas tarefas, como o gerador de grafos do modelo de grafos aleatórios de Erdős-Rényi [7], em que dois parâmetros são passados: o número de nós do grafo e a probabilidade de existir uma aresta entre quaisquer dois nós.

Capítulo 4

Avaliação

4.1 Metodologia da avaliação

Como discutido no capítulo 3, de forma a possibilitar a avaliação dos resultados gerados pelo algoritmo desenvolvido foram utilizadas redes que não são anonimizadas nesta seção, de modo que este trabalho simule a anonimização da rede após a criação dos atacantes. Caso o processo obtenha sucesso, pela definição do algoritmo, não seria necessário conhecer a rede inicial, uma vez que se foi encontrado apenas um subgrafo de atacantes, é possível identificar os nós atacados, sem a informação de mapeamento entre os identificadores reais e os anonimizados. Entretanto, se o algoritmo falhar, esse mapeamento serve para identificar o motivo da falha, isto é, se foi um problema de isomorfismo ou automorfismo.

Todas as redes apresentadas na seção de resultados, portanto, são redes reais ou redes aleatórias criadas a partir de modelos matemáticos de redes. Para cada rede e para cada número de nós atacados, que pode variar entre um e o número de nós da rede, foram feitas 50 execuções. Na execução do processo de criação de atacantes, o número máximo de vezes que o processo pode encontrar um possível automorfismo e, portanto, refazer todo o processo de geração do subgrafo de atacantes é igual a 10. O número máximo de nós folhas que as árvores podem ter, no processo de recuperação do subgrafo criado, é igual a 10000.

Além disso, apenas grafos não-direcionados foram utilizados para a avaliação do algoritmo. Como em grafos direcionados existem mais informações sobre cada nó (por exemplo: graus de entrada e de saída ao em vez de apenas um grau), o processo de encontrar nós a partir da estrutura da rede se torna mais fácil. Ademais, o algoritmo foi desenvolvido especialmente para grafos não-direcionados, de modo a não fazer distinção entre o sentido de uma aresta. Vale ressaltar que o algoritmo pode ser remodelado de modo a aceitar redes direcionadas e, então, analisar a eficácia do método.

4.2 Resultados

Pelo fato do processo de recuperação do subgrafo precisar carregar o grafo inteiro em memória e para a avaliação do ataque possuir mais dados, isto é, muitas execuções para diferentes redes e número de nós sendo atacados, o número de nós das redes atacadas se encontra na casa dos milhares.

Os resultados dispostos nesta seção representam a quantidade de sucessos por rede e número de nós atacados, normalizado pelo número de execuções, de modo a variar entre 0 e 1. No caso de ocorrerem falhas, resultados demonstrando o tipo de falha, isomorfismo ou automorfismo, também serão apresentados de maneira similar.

4.2.1 Grafos aleatórios

Esta subseção irá apresentar o desempenho do algoritmo quando executado em duas redes geradas a partir de modelos matemáticos, em que suas estruturas topológicas são aleatórias, isto é, a formação de arestas segue regras de formação com aleatoriedade.

Erdős-Rényi [7]

O modelo Erdős-Rényi, mais especificamente o modelo $G(n,p)$ é um modelo matemático que recebe dois parâmetros: o número de nós que a rede deve ter, representado pela letra n , e a probabilidade de existir uma aresta entre dois nós. Cada aresta é incluída no grafo de maneira independente e com mesma probabilidade, representada pela letra p .

Para a execução deste processo, utilizamos 1000 nós para a rede e diferentes valores de p , variando de 0.01 a 0.5. Conforme aumentamos o valor de p , o número de arestas aumenta consideravelmente: no caso em que p vale 0.5, com 1000 nós na rede, existem 250 mil arestas. Por esse motivo, não foram utilizados valores de p maiores que 0.5 (como p representa um valor probabilístico, ele pode variar entre 0 e 1).

Para cada combinação de p e número de nós atacados, 50 execuções foram feitas, gerando uma nova rede seguindo o modelo aleatório descrito a cada uma delas. Foram escolhidas 152 combinações diferentes de valores para a probabilidade p de existir uma aresta entre dois nós e número de nós atacados, de modo a serem feitas 7600 execuções deste processo, representadas na tabela 4.1. É possível, portanto, reparar que apenas uma execução não foi sucedida de todas as executadas: um erro ao atacar todos os nós da rede com probabilidade de existir uma aresta entre dois nós igual a 1%.

Este erro foi causado por um isomorfismo, isto é, pelo menos um nó não atacante

foi confundido com um nó atacante. Para entender o que aconteceu, é preciso analisar a rede em que o ataque não foi sucedido: um modelo de rede de Erdős-Rényi com 1000 nós e probabilidade de existir uma aresta entre dois nós igual a 1%. No caso, todos os nós da rede estão sendo atacados e existem 20 nós atacantes. Além disso, sabemos que o valor esperado do grau dos nós de uma rede seguindo este modelo é igual ao número de nós vezes a probabilidade de existir uma aresta entre dois nós, ou seja, 10. Pela maneira como conectamos os nós atacantes aos nós atacados, descrita no capítulo 3, apenas parte dos atacantes são relacionados a atacados: neste caso, apenas metade dos atacantes possui arestas com nós atacados. Assim, a outra metade está apenas conectada com os próprios atacantes, uma vez que não existem nós não atacados para eles se conectarem, já que a rede inteira está sendo atacada. Como cada nó atacante se conecta aos demais atacantes com probabilidade igual a 50%, é possível calcularmos o valor esperado do grau dos atacantes que não possuem arestas com os nós atacados da mesma maneira que calculamos para o grafo inicial: multiplicar o número de atacantes pela probabilidade de existir uma aresta entre eles, ou seja, $20 * 0.5$, encontrando um valor igual a 10, igual ao valor esperado para o grau dos nós atacados. É possível, portanto, perceber que existem muitos nós atacados com valor esperado de grau muito próximo (e até mesmo igual) ao valor esperado de grau de alguns nós atacantes. Uma vez que o grau de um atacante é igual ao de um atacado, utilizamos a parte da sequência de grau dos vizinhos para tentar identificá-los, porém, dada a grande quantidade de nós com grau igual, é capaz que não seja suficiente e o isomorfismo aconteça.

Tabela 4.1: Desempenho do algoritmo no modelo Erdős-Rényi.

Nº Atacados	p=0.01	p=0.05	p=0.08	p=0.1	p=0.2	p=0.3	p=0.4	0.5
2	1	1	1	1	1	1	1	1
4	1	1	1	1	1	1	1	1
8	1	1	1	1	1	1	1	1
16	1	1	1	1	1	1	1	1
32	1	1	1	1	1	1	1	1
64	1	1	1	1	1	1	1	1
100	1	1	1	1	1	1	1	1
128	1	1	1	1	1	1	1	1
200	1	1	1	1	1	1	1	1
256	1	1	1	1	1	1	1	1
300	1	1	1	1	1	1	1	1
400	1	1	1	1	1	1	1	1

Tabela 4.1 – continuação

Nº Atacados	p=0.01	p=0.05	p=0.08	p=0.1	p=0.2	p=0.3	p=0.4	0.5
500	1	1	1	1	1	1	1	1
512	1	1	1	1	1	1	1	1
600	1	1	1	1	1	1	1	1
700	1	1	1	1	1	1	1	1
800	1	1	1	1	1	1	1	1
900	1	1	1	1	1	1	1	1
1000	0.98	1	1	1	1	1	1	1

Barabasi-Albert (BA) [8]

Este modelo de rede aleatório segue uma regra muito antiga de formação de grupos, chamada de *preferential attachment* em inglês. A ideia principal é que objetos têm preferência em se relacionar com objetos mais populares, ou seja, no caso de redes, os objetos são os vértices, as relações as arestas e a popularidade é dada pelo grau do vértice.

Este modelo de rede possui dois parâmetros principais: o número de nós do grafo, representado pela letra n , e o grau mínimo de cada nó, representado pela letra m . O processo de formação desse modelo de redes é feito de maneira iterativa, conforme descrito a seguir:

1. Inicialmente, um pequeno clique é formado, isto é, um grafo em que todos os vértices estão conectados entre si. O número de nós do clique é consideravelmente menor do que n .
2. A cada iteração, um novo vértice com grau m é adicionado.
3. Os m vértices que terão arestas incidentes a este novo vértice, de modo que o seu grau seja igual a m nesta iteração, serão escolhidos aleatoriamente dentre os vértices já adicionados à rede, com probabilidade proporcional ao seus graus. Isto é, vértices com maior grau possuem maior chance de se relacionarem a este novo vértice.

Representado o número da iteração pela letra t , é possível descrever a probabilidade de um vértice u , já adicionado à rede ser incidente à uma nova aresta no instante t pela seguinte equação, em que $d_u(t)$ é o grau do vértice u no instante t e a letra V representa o conjunto de vértices do grafo no instante t :

$$p_u(t) = \frac{d_u(t)}{\sum_{v \in V} d_v(t)} = \frac{d_u(t)}{2mt}$$

4. Repetir itens 2 e 3 até que o grafo possua n nós.

O modelo Barabási–Albert (BA) gera redes sem escala, com distribuição de grau do tipo lei de potência, consequentemente tendo uma cauda pesada, propriedade amplamente observada em diversas redes complexas naturais e artificiais, como a web e algumas redes sociais.

Para a geração dos grafos utilizados para a avaliação do algoritmo proposto, este trabalho utilizou a biblioteca *graph-tool* na linguagem de programação python, que possui uma função que recebe os parâmetros m e n definidos pelo usuário e cria grafos não-direcionados respeitando o modelo descrito.

Foram escolhidos sete valores diferentes para o valor m , que representa o grau mínimo de cada nó, e dezenove valores para a quantidade de nós atacados no grafo. Todos os grafos deste modelo criado possuem 1000 nós. Para cada possível configuração de teste, isto é, para cada combinação entre m e número de atacados, foram feitas 50 execuções do algoritmo. A quantidade de sucessos está representada na tabela 4.2, que foi normalizada pela quantidade de execuções. Dessa forma, 6650 execuções diferentes foram feitas, das quais apenas 18 não foram sucedidas, tendo sido as falhas causadas por isomorfismos.

A partir da tabela 4.2, é possível perceber um certo padrão em relação aos erros: aproximadamente 83% deles ocorreram quando m é igual a 10 e os demais quando m é igual a 5, não ocorrendo erros nos demais valores de m . Como este modelo possui distribuição de grau com cauda pesada, existem muitos nós com grau baixo, próximo ao grau mínimo, e poucos nós com grau elevado - porém uma quantidade não desprezível de nós. Utilizando a mesma lógica da falha causada no modelo $G(n,p)$, quando m é igual a 10, existem muitos nós da rede atacada com grau próximo dos graus de alguns atacantes, de modo que ocorreram casos em que pelo menos um nó atacante e um nó da rede original tivessem o mesmo grau e a parte da sequência de grau dos vizinhos do atacante conhecida estivesse contida no nó não atacante.

Tabela 4.2: Desempenho do algoritmo no modelo Barabási-Albert.

Nº Atacados	$m=5$	$m=10$	$m=20$	$m=30$	$m=40$	$m=50$	$m=100$
2	1	1	1	1	1	1	1
4	1	0.98	1	1	1	1	1
8	1	1	1	1	1	1	1
16	1	0.98	1	1	1	1	1
32	1	0.94	1	1	1	1	1
64	1	0.94	1	1	1	1	1

Tabela 4.2 – continuação

Nº Atacados	m=5	m=10	m=20	m=30	m=40	m=50	m=100
100	1	0.94	1	1	1	1	1
128	0.98	0.96	1	1	1	1	1
200	1	1	1	1	1	1	1
256	1	1	1	1	1	1	1
300	1	1	1	1	1	1	1
400	1	1	1	1	1	1	1
500	1	1	1	1	1	1	1
512	1	0.98	1	1	1	1	1
600	1	1	1	1	1	1	1
700	1	1	1	1	1	1	1
800	0.98	1	1	1	1	1	1
900	1	0.98	1	1	1	1	1
1000	0.98	1	1	1	1	1	1

4.2.2 Redes reais

Esta subseção irá apresentar o desempenho do algoritmo em três redes reais, retiradas da base de dados do projeto de análise de redes de Stanford, liderado por Jure Leskovec [9].

Facebook

Este rede consiste de alguns círculos, ou listas de amigos, existentes no Facebook, coletada a partir de uma pesquisa de usuários que estavam usando o aplicativo desta rede social. A rede possui mais dados além de sua estrutura, porém este projeto só utiliza as informações de relacionamento entre os usuários.

Os dados foram anonimizados antes de serem publicados pelo grupo de Stanford em seu *website*, porém consideramos neste trabalho que os dados publicados são reais e faremos a comparação entre os resultados encontrados por este modelo e os dados da rede utilizada.

A rede é conexa, possui 4039 nós e 88234 arestas, o diâmetro (maior caminho mínimo) vale 8 e o coeficiente de clusterização médio 0.6055. É interessante perceber que esta rede, mesmo sendo pequena, possui características comuns de redes sociais, como alto valor de clusterização e baixo valor de diâmetro.

Novamente, foram feitas cinquenta execuções para cada número de nós a serem atacados escolhidos, ou seja, 2600 execuções diferentes foram feitas. Cada linha

da tabela 4.3 representa a quantidade de sucessos, normalizada pelo número de execuções, para um determinado número de nós atacados. De todas as execuções feitas, apenas oito erros ocorreram, todos do tipo isomorfismo. O único caso em que dois erros ocorreram na mesma configuração, isto é, com o mesmo número de nós atacados foi no caso que atacamos a rede inteira. Nos demais casos, apenas um erro, ou nenhum, aconteceu.

Tabela 4.3: Desempenho do algoritmo em uma rede do Facebook.

Nº Atacados	Desempenho
2	1
4	1
8	1
16	1
32	0.98
64	1
100	0.98
128	1
200	1
256	1
300	1
400	0.98
500	1
512	1
600	1
700	1
800	1
900	1
1000	1
1024	1
1100	1
1200	1
1300	1
1400	1
1500	1
1600	1
1700	1
1800	1

Tabela 4.3 – continuação

Nº Atacados	Desempenho
1900	1
2000	1
2048	1
2100	1
2200	1
2300	1
2400	1
2500	1
2600	1
2700	1
2800	1
2900	1
3000	0.98
3100	1
3200	0.98
3300	1
3400	1
3500	0.98
3600	1
3700	1
3800	1
3900	1
4000	1
4039	0.96

Votação na Wikipédia

A Wikipédia é uma enciclopédia gratuita escrita colaborativamente por voluntários ao redor do mundo. Uma pequena parte dos contribuidores desta rede social são administradores, que são usuários com acesso a recursos técnicos adicionais que auxiliam na manutenção. Para um usuário se tornar administrador, é preciso que o usuário emita um pedido para administração e a comunidade da Wikipédia, por meio de uma discussão pública ou votação, decida quais usuários serão promovidos a administradores.

O grafo representa 2794 eleições, com um total de 103663 votos e 7066 usuários participando das eleições, isto é, todas as eleições que ocorreram desde o início da

enciclopédia virtual até Janeiro de 2008. Nesta rede, os nós representam os usuários do sistema e as arestas são direcionadas e representam o voto, isto é, se existe uma aresta saindo do nó i e atingindo o nó j , então o usuário i votou no usuário j . Como este trabalho tem como principal objetivo estudar o desempenho do algoritmo em grafos não-direcionados, nós transformamos o grafo em não-direcionado, isto é, o sentido das arestas foram removidos, de modo a apenas analisar a existência de uma aresta entre dois nós. Desta forma, o grafo trabalhado possui 7115 nós e 100762 arestas.

Ao todo, 1750 execuções diferentes foram feitas. Cada linha da tabela 4.4 representa a quantidade de sucessos, normalizada pelo número de execuções, para um determinado número de nós atacados. Para os 35 valores de nós atacados escolhidos, nenhum erro foi observado.

Tabela 4.4: Desempenho do algoritmo na rede de votação da Wikipédia.

Nº Atacados	Desempenho
2	1
4	1
8	1
16	1
32	1
64	1
100	1
128	1
200	1
256	1
300	1
400	1
500	1
512	1
600	1
700	1
800	1
900	1
1000	1
1024	1
1500	1
2000	1

Tabela 4.4 – continuação

Nº Atacados	Desempenho
2048	1
2500	1
3000	1
3500	1
4000	1
4096	1
4500	1
5000	1
5500	1
6000	1
6500	1
7000	1
7115	1

Gnutella P2P

Esta rede é uma sequência de *snapshots* da rede de compartilhamento de arquivo P2P (*peer-to-peer*) de Agosto de 2002. No total, existem 9 *snapshots* da rede coletada nesse período de tempo. Como esta rede é extremamente dinâmica, o conceito de *snapshot* surgiu para capturar os dados de maneira estática, de modo que ele representa o estado da rede em um determinado tempo. Existem 6301 nós na rede, que representam os *hosts* da topologia de rede Gnutella e 20777 arestas, que representam as conexões entre os *hosts*. A rede é conexa, isto é, existe apenas uma grande componente conexa com todos os nós dentro.

Mais uma vez, os dados representam um grafo direcionado. De modo a utilizar o método criado e analisar a eficiência do mesmo, a direção das arestas foi removida, assim, se existia uma aresta saindo do nó x e chegando ao nó y, então existe uma aresta conectando os nós x e y sem direção no grafo não-direcionado.

A tabela 4.5 representa a quantidade de sucessos obtidos pelo algoritmo, normalizado pela quantidade de vezes que cada configuração foi executada. Para cada valor diferente de número de nós atacados o algoritmo foi executado 50 vezes, totalizando 2200 execuções. É possível observar que apenas uma dessas execuções não foi sucedida, quando o número de atacados foi igual a 6250. O erro causado foi, novamente, isomorfismo.

Tabela 4.5: Desempenho do algoritmo na rede de compartilhamento de arquivo Gnutella P2P.

NºAtacados	Desempenho
2	1
4	1
8	1
16	1
32	1
64	1
100	1
128	1
200	1
256	1
300	1
400	1
500	1
512	1
600	1
700	1
800	1
900	1
1000	1
1024	1
1250	1
1500	1
1750	1
2000	1
2048	1
2250	1
2500	1
2750	1
3000	1
3250	1
3500	1
3750	1
4000	1
4096	1
4250	1

Tabela 4.5 – continuação

Nº Atacados	Desempenho
4500	1
4750	1
5000	1
5250	1
5500	1
5750	1
6000	1
6250	0.98
6301	1

Capítulo 5

Detecção do ataque

Como abordado na introdução, este trabalho se baseia na promoção de um ataque ativo, criando um subgrafo de novos usuários, chamados de atacantes, de modo a ser possível reconhecê-lo, na rede anonimizada, a partir de duas informações estruturais de cada atacante: o grau e a sequência de grau dos vizinhos que são atacantes.

Esta seção irá abordar a detecção do ataque, isto é, se seria possível identificar que usuários foram inseridos na rede para atacá-la. Uma vez que o objetivo deste trabalho é, principalmente, focar no desenvolvimento e desempenho do ataque em si e não tanto em sua detecção, utilizaremos apenas uma técnica, muito conhecida no mundo de redes complexas, chamada de detecção de comunidades, que é detalhadamente explicada no capítulo 9 do [10].

5.1 Detecção de comunidade

O processo de detecção de comunidade tem como objetivo separar os vértices do grafo em grupos, conhecidos por *clusters*, a partir de características em comum entre os vértices. Cada grupo dá origem a uma comunidade. A ideia é que as comunidades são formadas por nós altamente conectados enquanto nós pertencentes a diferentes comunidades são fracamente conectados.

Para avaliar a detecção do ataque proposto por esse trabalho, utilizamos o algoritmo de detecção de comunidades disponibilizado no *software Gephi*, uma plataforma de visualização interativa, que foi utilizada para gerar os grafos do capítulo 3, e exploração para todos os tipos de redes e sistemas complexos e dinâmicos.

O programa implementa o método de Louvain [11] para a detecção de comunidades, que utiliza a otimização de modularidade para encontrar comunidades.

5.1.1 Método de Louvain

Modularidade

Modularidade é uma função que mede a qualidade de uma partição, ou comunidade, representada pela letra Q , que varia entre -1 e 1.

$$Q = \frac{1}{2m} \sum_{i,j} [A_{ij} - \frac{k_i k_j}{2m}] \delta(c_i, c_j)$$

em que A_{ij} é o peso da aresta entre os nós i e j , k_i é $\sum_j A_{ij}$, m é igual a $\frac{1}{2} \sum_{i,j} A_{ij}$. c_i representa a comunidade à qual o vértice i pertence e $\delta(c_i, c_j)$ vale 1 se $c_i = c_j$ e 0 caso contrário. As variáveis i e j variam dentro do conjunto de vértices do grafo.

Apesar da análise de modularidade ser feita para grafos com peso, os grafos utilizados ao longo deste trabalho foram grafos com arestas sem pesos, o que seria uma ideia similar a um grafo com pesos em que todas as arestas possuem o mesmo peso, igual a 1. Esse detalhe não impacta a detecção de comunidades nos grafos, existindo, inclusive, a opção de configurar no *Gephi* arestas sem peso.

Algoritmo

Inicialmente, todos os nós pertencem às suas próprias comunidades, isto é existem N comunidades, sendo N o número de nós, com um nó em cada. O algoritmo é baseado em dois passos que são iterativamente repetidos.

1. O processo analisa todos os nós de maneira ordenada, isto é, a partir do nó 1 até o nó N . Cada vértice, por sua vez, olha para os seus vizinhos e passa a fazer parte da comunidade de seu vizinho se tiver um aumento no valor da modularidade até então calculada para a comunidade que antes ele participava. Este passo é repetido até que um valor de máximo local para a modularidade é atingido, de modo que cada nó pode ser considerado várias vezes.
2. Uma vez que o valor local máximo para a modularidade tiver sido atingido, o processo cria um novo grafo em que os nós representam as comunidades formadas. O peso das arestas entre as comunidades é o peso total das arestas entre os nós pertencentes a cada comunidade. Geralmente, o número de nós diminui drasticamente nesta etapa, o que garante a rapidez do algoritmo para grandes redes.

Os passos 1 e 2 são repetidos iterativamente, conduzindo assim a uma decomposição hierárquica da rede.

5.1.2 Resultados

A função que calcula a modularidade e separa o grafo em comunidades no software utilizado recebe um parâmetro, chamado resolução, que regula a quantidade de comunidades distintas geradas. Por padrão, vale 1.0, porém pode ser alterado. Valores menores para resolução geram mais comunidades menores, enquanto valores maiores geram menos comunidades maiores.

Esta subseção irá apresentar resultados de algumas execuções deste algoritmo feitas em redes utilizadas ao longo deste trabalho, após terem sofrido o ataque, isto é, após a criação dos usuários atacantes. O objetivo será determinar a capacidade do algoritmo de agrupar os atacantes, sem qualquer informação sobre estes nós.

Para cada análise, dois parâmetros serão importantes: resolução, que definirá o número e tamanho das comunidades, e número de nós atacados, uma vez que influencia diretamente na quantidade de arestas que cada nó atacante possui, o que é usado no cálculo da modularidade. Para cada rede e caso de quantidade de nós atacados, o algoritmo de criação dos atacantes e suas arestas foi executado apenas uma vez, sendo o grafo gerado analisado.

Para cada análise, os resultados serão expostos em uma tabela. Para cada valor de resolução, o número de comunidades encontradas é apresentado. Além disso, para a comunidade com a maior quantidade de nós atacantes, são mostrados dois valores, em porcentagem: de todos os nós atacantes, quantos estão nesta comunidade, que será representada pela letra A; de todos os nós na comunidade, quantos são atacantes, representada pela letra B.

Rede do Facebook

Relembrando, a rede inicial é conexa e possui 4039 nós e 88234 arestas. Consequentemente, a rede após o ataque também será conexa, uma vez que o subgrafo formado pelos nós atacantes é conexo - toda aresta (x_i, x_{i+1}) existe e pelo menos um atacante está conectado a um nó atacado. O grafo pós ataque possui $4039 + 2 * \lceil \log_2(4039) \rceil$ nós, isto é, os nós da rede mais os 24 nós atacantes, resultando em 4063 nós, independentemente do número de atacados. O número de arestas, entretanto, irá variar com o número de nós que estão sendo atacados.

Para este estudo, foram utilizados dez nós atacados. Os resultados, variando o valor da resolução utilizado, podem ser encontrados na tabela 5.1. Analisando os resultados apresentados, é possível observar que o algoritmo é capaz de agrupar os nós atacantes em um único grupo, tendo dificuldade, apenas, em não adicionar à comunidade de atacantes nós não atacantes sem que isso aumente muito o número de comunidades.

Tabela 5.1: Comunidades na rede do Facebook.

Resolução	Nº Comunidades	A	B
1.0	15	100%	20.17%
2.0	11	95.83%	7.74%
0.5	20	100%	16%
0.1	143	100%	57.14%
0.05	286	100%	68.57%

Rede Gnutella P2P

A análise dos resultados de detecção de comunidades foi feita na rede Gnutella P2P, detalhada no capítulo 4, após ter sofrido um ataque de quebra de privacidade em 100 nós. Esta rede possui 6301 nós e, consequentemente, 26 atacantes, de modo que a rede analisada tenha 6327 nós, uma vez que a análise é feita na rede após a inserção dos atacantes.

Na tabela 5.2 é possível observar alguns resultados diferentes da execução do algoritmo de detecção de comunidades. Ao aumentar o valor da resolução, o algoritmo coloca todos os nós atacantes em uma mesma comunidade, porém com muitos outros nós não atacantes. Ao diminuir a resolução, os nós atacantes começam a não ficar mais em uma mesma comunidade, uma vez que o número de comunidades aumenta, também não conseguindo separar atacantes de não atacantes. A partir dos resultados apresentados, é possível afirmar que não foi possível fazer a detecção do ataque neste caso.

Tabela 5.2: Comunidades na rede Gnutella P2P.

Resolução	Nº Comunidades	A	B
0.5	57	69.23%	9.37%
0.8	33	100%	2.12%
1.0	21	100%	3.50%
2.0	2	100%	0.70%

Modelo Erdős-Rényi

Para o estudo da detecção de comunidades no modelo de rede aleatório de Erdős-Rényi, foram utilizados 100 nós, probabilidade de existir uma aresta entre dois nós

igual a 0.01 e 30 nós sendo atacados. No caso, são criados 14 nós atacantes.

A partir dos resultados apresentados na tabela 5.3 é possível observar que para valores baixos de resolução, menores iguais a 2.0, o algoritmo não é capaz de agrupar mais de 60% dos nós em uma mesma comunidade. No caso em que resolução é igual a 3.0, o algoritmo não consegue separar em mais de uma comunidade, agrupando todos os nós do grafo. Para resolução igual a 2.75, o algoritmo separou o grafo em duas comunidades, uma contendo todos os nós atacantes, porém com mais 77 outros nós não atacantes, deixando a outra comunidade com apenas 23 nós não atacantes. A partir dos resultados obtidos, o algoritmo não foi capaz de detectar os atacantes criados.

Tabela 5.3: Comunidades na rede do modelo Erdős-Rényi.

Resolução	NºComunidades	A	B
0.5	12	14.28%	22.22%
0.75	8	21.14%	25%
1.0	5	35.71%	17.86%
2.0	3	57.14%	18.60%
2.75	2	100%	18.18%
3.0	1	100%	12.28%

Capítulo 6

Conclusão e trabalhos futuros

6.1 Conclusão

O objetivo principal deste trabalho é analisar o desempenho de um método desenvolvido que fosse capaz de identificar nós pré-determinados de um grafo anonimizado, independentemente da quantidade de nós escolhidos para sofrerem essa violação de privacidade. No capítulo 4 apresentamos os resultados de mais de 20 mil execuções do algoritmo, em diferentes redes, reais e aleatórias. Em todos os casos, tivemos mais de 99% das execuções bem sucedidas.

Todas as falhas que ocorreram foram causadas por isomorfismos, diferentemente do trabalho [2] que prova que com alta probabilidade isomorfismos não ocorrem, porém nada diz sobre a existência de automorfismos, que não foram encontrados neste trabalho. O teorema para provar que a probabilidade de um isomorfismo acontecer após a criação do ataque no trabalho [2] tende a zero requer que exista um limite superior para o tamanho do conjunto de nós atacados, impossibilitando atacar o grafo inteiro, como fizemos neste projeto. Dessa forma, precisamos deixar o teorema de fora deste trabalho de modo a analisar os resultados de não existirem limites para a quantidade de nós atacados e o desempenho do algoritmo foi satisfatório.

Conforme falado no capítulo 2, o trabalho proposto em [3] afirma que grafos aleatórios esparsos têm baixo risco de sofrerem um ataque de identificação estrutural, como o proposto neste trabalho, bem sucedido. Entretanto, o nosso trabalho não tenta fazer a identificação dos nós no grafo original, mas apenas do subgrafo de atacantes criado, que é denso.

Além disso, por termos trabalhado com um ataque ativo, isto é, criado um ataque contra privacidade que influencia diretamente na estrutura da rede a ser atacada, tivemos a preocupação de analisar se o ataque seria facilmente detectado. Para isso, analisamos os resultados de um algoritmo conhecido de detecção de comunidades

para ver se ele seria capaz de separar o subgrafo de atacantes do subgrafo com os nós originais. Para todas as execuções feitas, o algoritmo não foi bem sucedido em criar apenas esses dois grupos e teve dificuldades em gerar comunidades formadas apenas com todos os nós atacantes, de modo que a conclusão tirada seja que esse algoritmo não seria capaz de detectar o ataque feito.

Dessa forma, os resultados do ataque são satisfatórios, uma vez que ele é capaz de identificar os nós pré-determinados no grafo anonimizado na maior parte das vezes e não é facilmente detectado pelo algoritmo de detecção utilizado.

6.2 Trabalhos futuros

6.2.1 Maior abrangência

O algoritmo deve ser avaliado para mais redes, de forma a tornar sólidas as conclusões feitas neste trabalho. Também deve ser avaliado para redes maiores, de forma a determinar se a medida que a rede cresce o ataque tem a mesma eficácia que para redes menores. Além disso, cabe executar para outros conjuntos de nós a serem atacados.

6.2.2 Comparações

Este trabalho tem como objetivo apresentar o método desenvolvido e seu desempenho, porém sem fazer grandes comparações com outros métodos propostos de ataques ativos de quebra de privacidade em redes anonimizadas. Sendo assim, um trabalho futuro seria procurar por mais algoritmos que tenham um objetivo final similar ao descrito ao decorrer deste trabalho e comparar o desempenho destes trabalhos com o descrito neste estudo.

6.2.3 Remoção de arestas

É muito comum ter arestas removidas aleatoriamente nas redes que são divulgadas anonimizadas. Nesses casos, de modo a não impactar fortemente a estrutura da rede, uma porcentagem específica de arestas costuma ser apagada, sendo essa informação também conhecida, para que quem estiver realizando estudos sobre a rede possa fazer aproximações sobre os dados para obter valores interessantes e realistas.

Sendo assim, é possível pensar em adaptar este projeto para considerar que uma porcentagem das arestas do grafo foram removidas. Isto é, antes da divulgação da rede, após o processo de criação dos atacantes, de modo que informações criadas pelo promotor do ataque possam ser também apagadas, como uma aresta entre um nó atacante e um nó atacado. Dessa forma, não é mais possível confiar fortemente

nos valores de grau e sequência de grau dos vizinhos atacantes, que são usados para identificar os atacantes no grafo anonimizado.

6.2.4 Detecção do ataque

Este trabalho teve como objetivo principal desenvolver um algoritmo de ataque de quebra de privacidade em grafos anonimizados e analisar seu desempenho. No capítulo 5 apresentamos um algoritmo específico para analisar se seria possível detectar o ataque, baseado na detecção de comunidade em redes, porém uma análise mais extensa não foi feita. Para próximos trabalhos, seria interessante analisar com outros métodos de detecção de ataques se o algoritmo proposto seria detectado ou não, de modo a adaptá-lo, caso necessário, para evitar sua detecção.

Referências Bibliográficas

- [1] WIKIPEDIA - THE FREE ENCYCLOPEDIA. “Netflix Prize”. . https://en.wikipedia.org/wiki/Netflix_Prize, jul. 2017. Acessado em julho de 2017.
- [2] BACKSTROM, LARS; KLEINBERG, JON; DWORK, CYNTHIA;. “Wherefore Art Thou R3579X? Anonymized Social Networks, Hidden Patterns, and Structural Steganography”. . https://utd.edu/~mxk055100/courses/privacy08f_files/social-network-privacy-backstrom.pdf, mai. 2007. Acessado em julho de 2017.
- [3] HAY, MICHAEL; MIKLAU, GEROME; JENSEN, DAVID; TOWSLEY, DON; LIN, CHAO. “Resisting Structural Re-identification in Anonymized Social Networks”. . <http://www.vldb.org/pvldb/1/1453873.pdf>, ago. 2008. Acessado em julho de 2017.
- [4] CORNEIL, D. G., GOTLIEB, C. C. “An Efficient Algorithm for Graph Isomorphism”, *J. ACM*, v. 17, n. 1, pp. 51–64, jan. 1970. ISSN: 0004-5411. Disponível em: <http://doi.acm.org/10.1145/321556.321562>.
- [5] WIKIPEDIA - THE FREE ENCYCLOPEDIA. “Graph Isomorphism”. . https://en.wikipedia.org/wiki/Graph_isomorphism, jul. 2017. Acessado em julho de 2017.
- [6] WIKIPEDIA - THE FREE ENCYCLOPEDIA. “Graph Automorphism”. . https://en.wikipedia.org/wiki/Graph_automorphism, jul. 2017. Acessado em julho de 2017.
- [7] ERDŐS, PAUL; RÉNYI, ALFRÉD. “On Random Graphs”. . http://www.renyi.hu/~p_erdos/1959-11.pdf, nov. 1958. Acessado em julho de 2017.
- [8] BARABÁSI, ALBERT-LÁSZLÓ; ALBERT, RÉKA. “Emergence of scaling in random networks”. . *Science* 286, 509-512. Acessado em julho de 2017.
- [9] LESKOVEC, J., KREVL, A. “SNAP Datasets: Stanford Large Network Dataset Collection”. . <http://snap.stanford.edu/data>, jun. 2014.

- [10] BARABÁSI, ALBERT-LÁSZLÓ. *Network Science*. Acessado em julho de 2017.
- [11] BLONDEL, VINCENT D.;GUILLAUME, J.-L. R. L. E. “Fast unfolding of communities in large networks”, *Journal of Statistical Mechanics: Theory and Experiment*, v. 2008, n. 10, pp. P10008, 2008. Disponível em: <http://stacks.iop.org/1742-5468/2008/i=10/a=P10008>.